

Maschinelles Lernen 1 Induktives Lernen (Topic 2)

Induktion: plausibles Schließen vom Speziellen zum Allgemeinen
im Vergleich mit Deduktion

<u>Induktion</u>	<u>Deduktion</u>
- <u>Wahrheitsweiternd</u>	- <u>Wahrheitserhaltend</u>
- empirisch	- axiomatisch
- Plausibilität	- Korrektheit

Induktive Lernhypothese: jede Hyp., die die Zielfunktion über einer genügend großen Menge von Beispielen gut genug approximiert, wird die Zielfunktion auch über unbekannten Bsp. gut approximieren.

Konsistenz und Vollständigkeit im Hypothesenraum

Konsistenz: keine negativen Beispiele werden positiv klassifiziert

Vollständigkeit: alle positiven Beispiele werden als positiv klassifiziert

Specific-to-General-Suche

- nur positive Beispiele betrachtet (negative ignoriert)
- spezielle Hypothese $\langle \#, \dots, \# \rangle$ ist Ausgangspunkt
- sukzessive (attributweise) „aufweichen“ der Hyp.

Bsp. $h = \langle \text{sonnig, warm, normal, stark} \rangle$
 $x = \langle \text{sonnig, warm, hoch, stark} \rangle$

- ist x positiv? Ja
- wird x von h abgedeckt? Nein ($h(x) = \text{false}$)
- aktualisiere $h := \langle \text{sonnig, warm, ?, stark} \rangle$ sodass $h(x) = \text{true}$

General-to-Specific-Suche


- nur negative Beispiele betrachtet (positive ignoriert)
- allgemeinste Hypothese $\langle ?, \dots, ? \rangle$ ist Ausgangspunkt
- sukzessive (attributweise) „strenger machen“ der Hyp.

Version Space Algorithmus

- Kombination von General-to-Specific-Suche und Specific-to-General-Suche
- Startpunkt(=) sind zwei Hypothesen:
 - Spezifischste Hypothese
 - Allgemeinste Hypothese

(5) Spezifischste Hypothese: generalisiert durch positive Beispiele, gestützt durch negative Beispiele

(6) Allgemeinste Hypothese: spezialisiert durch negative Beispiele, gestützt durch positive Beispiele



Version Space Beurteilung

→ konvergiert zur korrekten Hypothese ($S=G$)

Voraussetzung: Beispiele konsistent, korrekte Hypothese im Hypothesenraum enthalten (d.h. $h(x) = c(x)$ für $\forall x: x \in X$ bzw. h erfüllt Zielbeschreibung und befindet sich im Raum der durch Attributvariationen konstruiert ist) + Konjunktion

Probleme: • fehlerbehaftete Trainingsdaten, • Zielkonzept nicht von Hypothesenrepräsentation abgedeckt

- wenn mehr als ein korrektes h ?
→ Mehrheitsentscheidung

Vor- und Nachteile:

- ⊕ kein Speichern aller Beispiele notwendig
- ⊕ Terminierung erkennlich ($S=G$)
- ⊖ konsistente Beispiele notwendig
- ⊖ Regeln für Attributgeneralisierung entscheiden über Lernerfolg

Induktiver Bias

Grundlegende Eigenschaft von induktives Inferenz:

Ein induktives Lernsystem, das keine a priori-Annahmen über das Zielkonzept macht, hat keine rationale Basis, um unbekannte Instanzen zu klassifizieren

⇒ Daher: induktives Lernen erfordert Vorannahmen: „inductive Bias“

Hypothesenraum (Restriktionsbias) und Präferenzbias

Restriktionsbias: z.B. h gehöre zu einem beschränkten Raum von Hypothesen mit lineare Schwellwertfunktionen

Präferenzbias: Ordnung auf dem Raum der Hypothesen. Wähle h mit höchster Präferenz, z.B. bevorzuge Hyp. mit weniger Disjunktionen oder bevorzuge kleinere Entscheidungsbäume

Annahme: es existiert keine Funktion h , die konsistent mit allen Trainingsbeispielen ist, z.B. weil Daten verrauscht sind

Möglichkeiten: 1) Anpassen des Restriktionsbias (z.B. komplexere Hypothesen)
2) Anpassen des Präferenzbias (wähle h , das möglichst viele Beispiele richtig klassifiziert)